METODE WORD2VEC DAN BERT UNTUK SUMARISASI TEKS DESKRIPTIF BEBATUAN GEOLOGI

WORD2VEC *AND BERT METHODS FOR SUMMARIZING DESCRIPTIVE TEXTS OF GEOLOGICAL ROCKS*

Eldo Hidayat Arianto[1]

[1]Program Studi Sistem Informasi, Universitas Komputer Indonesia, Bandung, Indonesia

E-mail: eldohidayaat@gmail.com

Abstrak

Deskripsi batuan geologi hasil identifikasi cenderung kompleks dan panjang, menyulitkan geolog dalam melakukan analisis cepat. Penelitian ini bertujuan mengembangkan model sumarisasi teks otomatis untuk menghasilkan ringkasan deskripsi batuan yang ringkas dan informatif. Metode yang digunakan menggabungkan vektor representasi kata dari Word2Vec dan *embedding* kontekstual dari model SciBERT untuk meningkatkan akurasi algoritma TextRank. Evaluasi menggunakan metrik ROUGE, BLEU, dan Cosine Similarity terhadap data dari Museum Geologi Bandung. Hasil penelitian menunjukkan model BART mencapai performa terbaik dengan skor ROUGE-1 70.7%, ROUGE-L 70.7%, dan Cosine Similarity 84.9%. Model ini secara efektif menghasilkan ringkasan yang mempertahankan makna esensial dan istilah teknis kunci, sehingga dapat menjadi alat bantu yang berharga bagi geolog dalam mendokumentasikan dan menganalisis data batuan.

Kata Kunci: Sumarisasi Teks, Pemrosesan Bahasa Alami, Word2Vec , BERT, Geologi.

Abstract

Geological rock identification descriptions are often complex and lengthy, hindering geologists' rapid analysis. This study aims to develop an automatic text summarization model to generate concise and informative rock description summaries. The method combines word vector representations from Word2Vec *and contextual embeddings from the SciBERT model to enhance the accuracy of the* TextRank *algorithm. Evaluation using ROUGE, BLEU, and Cosine Similarity metrics was conducted on data from the Bandung Geological Museum. The results indicate that the BART model achieved the best performance with scores of 70.7% for ROUGE-1, 70.7% for ROUGE-L, and 84.9% for Cosine Similarity. This model effectively produces summaries that retain essential meaning and key technical terms, making it a valuable tool for geologists in documenting and analyzing rock data.*

Key Word: *Text Summarization, Natural Language Processing,* Word2Vec *, BERT, Geology.*

I. PENDAHULUAN

Geologi sebagai ilmu yang mempelajari bumi beserta material penyusunnya sangat bergantung pada data deskriptif yang akurat dan detail [4]. Deskripsi tekstual mengenai karakteristik batuan merupakan *output* fundamental dari berbagai kegiatan lapangan dan laboratorium, mulai dari pemetaan geologi, eksplorasi sumber daya mineral, hingga karakterisasi batuan untuk keperluan teknik geoteknik [2][5]. Setiap sampel batuan biasanya didokumentasikan dengan cermat mencakup berbagai atribut seperti warna, tekstur, komposisi mineral, struktur, ukuran butir, dan derajat alterasi. Tingkat detail ini sangat bernilai secara ilmiah karena memberikan catatan lengkap yang dapat dianalisis ulang di masa depan.

Namun, praktik dokumentasi yang ini menimbulkan tantangan signifikan dalam era *big data* geologi [2]. Deskripsi batuan yang dihasilkan seringkali sangat panjang, kompleks, dan sarat dengan istilah teknis khusus. Sebuah deskripsi batuan tunggal dapat mencapai puluhan hingga ratusan kata yang mencakup berbagai aspek teknis. Ketika dikumpulkan dalam jumlah besar, database deskripsi batuan menjadi sangat masif dan sulit dikelola. Para geolog menghadapi kesulitan dalam melakukan analisis cepat, pencarian informasi spesifik, dan komparasi antar sampel batuan dalam waktu singkat. Padahal, dalam konteks eksplorasi mineral atau

penilaian bahaya geologi, waktu seringkali menjadi faktor kritis yang menentukan kesuksesan suatu proyek [4].

Tantangan ini semakin memperoleh karena minimnya *tools* komputasional yang khusus dirancang untuk menangani teks teknis geologi. Sementara bidang lain seperti kedokteran atau hukum telah banyak mengadopsi teknik *Natural Language Processing* (NLP) untuk manajemen dokumen otomatis, domain geologi relatif tertinggal dalam adopsi teknologi ini [4][9]. Kebutuhan akan *tools* yang dapat menyederhanakan informasi tanpa menghilangkan makna esensial dan terminologi kunci menjadi semakin mendesak, khususnya dalam mengelola database geologi yang terus berkembang secara eksponensial.

Perkembangan terkini dalam bidang pemrosesan bahasa alami (NLP) dan *deep learning* menawarkan potensi solusi untuk masalah ini melalui tugas *text summarization* [7][10]. Teknik *summarization* modern tidak hanya mampu mengekstrak kalimat-kalimat kunci saja, tetapi juga menghasilkan ringkasan abstraktif yang memparafrasekan konten asli dengan lebih ringkas dan padat informasi [12][13]. Pendekatan ini sangat promising untuk diaplikasikan pada teks teknis geologi yang memiliki karakteristik bahasa yang unik dan spesifik.

Penelitian sebelumnya oleh Nursikuwagus et al. telah membuktikan efektivitas *deep learning* dan *word embedding* untuk menghasilkan deskripsi batuan secara otomatis dari gambar [3]. Namun, *output* dari penelitian tersebut cenderung sangat rinci dan panjang, sehingga justru memerlukan proses summarisasi lebih lanjut untuk analisis yang efisien. Di sisi lain, penelitian Lawley et al. lebih berfokus pada aplikasi NLP untuk klasifikasi teks dan pemodelan prospek mineral, bukan pada penyederhanaan teks deskriptif yang sudah ada [4]. Hal ini menunjukkan adanya kesenjangan (gap) penelitian yang secara khusus mengembangkan model untuk meringkas teks deskriptif geologi.

Berdasarkan latar belakang tersebut, penelitian ini mengusulkan pengembangan model *automatic text summarization* yang khusus dioptimalkan untuk teks deskriptif batuan geologi. Penelitian ini memanfaatkan *state-of-the-art* model *Transformer* seperti BERT, BART, dan T5 yang telah terbukti efektif untuk tugas *summarization* dalam berbagai domain lainnya [13][24]. Dengan mengombinasikan kekuatan *word embedding* konvensional dan con*text*ual *embedding* modern, penelitian ini bertujuan menciptakan *tools* yang dapat membantu geolog dalam mengelola dan menganalisis data tekstual secara lebih efisien.

II. KAJIAN PUSTAKA

Summarization

Penerapan *text summarization* dalam domain geologi masih relatif terbatas dibandingkan dengan bidang lainnya seperti biomedis atau hukum. Mayoritas penelitian *Natural Language Processing* (NLP) di *geosciences*, seperti yang dikemukakan oleh Lawley et al. (2023), berfokus pada klasifikasi teks, ekstraksi hubungan entitas, dan pemodelan prospek mineral [4]. Penelitian mereka menunjukkan bahwa teknik NLP dapat secara efektif mengidentifikasi dan mengekstrak informasi geologi penting dari literatur yang luas, namun belum menyentuh aspek penyederhanaan teks deskriptif yang sudah ada. Sementara itu, Nursikuwagus et al. (2022) berhasil mengembangkan *model image captioning* untuk menghasilkan deskripsi batuan dari gambar secara otomatis menggunakan pendekatan hybrid yang menggabungkan *deep learning* dan *word embedding* [3]. Meskipun *output* yang dihasilkan cukup akurat, deskripsi yang dihasilkan cenderung panjang dan rinci, sehingga justru memerlukan proses summarisasi lebih lanjut untuk analisis yang efisien.

Studi oleh Li et al. (2022) menggarisbawahi pentingnya pengembangan metode intelijen untuk prediksi sumber daya mineral dalam konteks *big data* geologi [2]. Mereka menekankan bahwa volume data geologi yang terus bertambah memerlukan teknik otomatis untuk pengolahan dan analisis informasi. Peyghambari dan Zhang (2021) dalam penelitiannya tentang *remote sensing hiperspektral* juga menyoroti kebutuhan akan teknik kompresi dan summarisasi data dalam geologi lingkungan [5]. Namun, fokus penelitian tersebut masih pada data numerik dan citra, bukan pada teks deskriptif.

Word embedding dan Vektorisasi Teknis

Vektorisasi teks merupakan langkah fundamental dalam NLP yang mentransformasikan teks menjadi representasi numerik yang dapat diproses oleh model komputasional [11][21]. Teknik *word embedding* memetakan kata-kata ke dalam ruang vektor berdimensi tinggi sehingga kata-kata dengan konteks semantik serupa memiliki representasi yang mirip [6][22]. Menurut Mahesh (2020), *word embedding* telah merevolusi bidang NLP dengan memungkinkan model untuk memahami hubungan semantik dan sintaksis antar kata [6].

Word2Vec , yang diperkenalkan oleh Mikolov et al. (2013), adalah salah satu teknik *word embedding* paling berpengaruh yang menggunakan arsitektur skip-gram atau continuous *bag-of-words* (CBOW) untuk

mempelajari representasi vektor kata [11][21]. Dalam konteks teknis seperti geologi, di mana kosakata khusus seperti "*breccia*", "*tuffaceous*", "*porphyritic*", dan "*matrix*" memiliki makna spesifik, Word2Vec yang dilatih pada korpus domain-spesifik dapat secara efektif mempelajari hubungan semantik antar istilah-istilah kunci tersebut [12]. Abubakar dan Umar (2022) melakukan review komprehensif tentang metode vektorisasi teks dan menyimpulkan bahwa Word2Vec memberikan performa yang unggul untuk teks teknis dibandingkan metode tradisional seperti *bag-of-words* atau TF-IDF [11][21].

Yulianti et al. (2023) mengusulkan *enhancement* pada algoritma TextRank dengan menggunakan weighted *word embedding* untuk tugas *text summarization* [12]. Mereka menunjukkan bahwa kombinasi antara *embedding* statis seperti Word2Vec dengan weighting yang sesuai dapat meningkatkan kualitas ringkasan secara signifikan. Pendekatan ini sangat relevan untuk domain geologi dimana istilah teknis tertentu memiliki tingkat penting yang berbeda-beda.

Model Transformer

Perkembangan model berbasis *Transformer* telah merevolusi bidang NLP dalam beberapa tahun terakhir [15][24]. Arsitektur *Transformer* yang diperkenalkan oleh Vaswani et al. (2017) memungkinkan pemrosesan paralel dan pemodelan ketergantungan jarak jauh yang lebih efektif dibandingkan arsitektur RNN atau LNN sebelumnya.

BERT (*Bidirectional Encoder Representations from Transformers*) yang diperkenalkan oleh Devlin et al. (2018) memperkenalkan konsep *pre-training* bidirectional untuk memahami konteks suatu kata dalam sebuah kalimat secara mendalam [24]. SciBERT, sebagai varian dari BERT, secara khusus dilatih pada korpus multidisiplin ilmiah yang mencakup 1.14M paper dari ilmu komputer dan biomedis [24]. Keunggulan SciBERT untuk teks ilmiah membuatnya lebih sesuai untuk memahami terminologi teknis geologi dibandingkan BERT umum. Zhang et al. (2019) menunjukkan bahwa model berbasis *pre-training* seperti BERT menghasilkan representasi kontekstual yang lebih kaya dibandingkan *word embedding* statis [24].

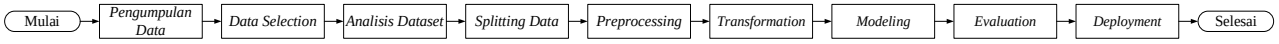
Di sisi lain, model *sequence-to-sequence* seperti BART dan T5 tidak hanya unggul dalam pemahaman (*encoding*) tetapi juga dalam pembuatan teks baru (*decoding*). BART, yang diperkenalkan oleh Lewis et al. (2019), dirancang sebagai *denoising autoencoder* yang sangat efektif untuk tugas generatif seperti summarisasi [13]. La Quatra dan Cagliero (2023) mengembangkan BART-IT yang menunjukkan efektivitas BART untuk tugas *summarization* teks dalam bahasa Italia [13]. Sementara T5 (*Text*-to-*Text Transfer Transformer*) yang diperkenalkan oleh Raffel et al. (2020) merangkum semua tugas NLP ke dalam paradigma *text*-to-*text*, memberikan fleksibilitas yang sangat tinggi [24].

Evaluasi Kualitas Ringkasan

Evaluasi otomatis kualitas ringkasan biasanya menggunakan metrik berbasis n-gram ove dan kesamaan semantik [25], [26]. Metrik ROUGE (*Recall-Oriented Understudy for Gisting Evaluation*) mengukur kesamaan unit n-gram antara ringkasan yang dihasilkan dengan ringkasan referensi [23]. Sementara BLEU (*Bilingual Evaluation Understudy*) lebih umum digunakan untuk terjemahan mesin dan mengukur presisi n-gram [24]. Untuk mengukur kesamaan makna yang lebih mendalam, *Cosine Similarity* antara vektor *embedding* dari teks asli dan teks ringkasan merupakan metrik yang robust, karena menangkap kesamaan semantik dalam ruang vektor, bukan hanya kesamaan literal kata [23]. Kombinasi dari ketiga metrik ini memberikan gambaran evaluasi yang komprehensif.

III. METODE PENELITIAN

Penelitian ini mengikuti alur metodologi yang terstruktur, dimulai dari pengumpulan data, seleksi, analisis, *splitting data*, *Preprocessing*, transformasi, pemodelan, evaluasi, hingga *Deployment*. Secara keseluruhan, alur penelitian dapat dilihat pada Gambar 1 di bawah.



Gambar 1. Alur Preprocessing

Pengumpulan Data

Data yang digunakan merupakan teks deskriptif batuan geologi dalam bahasa Inggris yang bersumber dari arsip laporan penelitian Museum Geologi Bandung. Data awal memiliki 267 sampel dengan 14 atribut. Melalui tahap seleksi, hanya dua atribut yang digunakan: *station* (yang diubah menjadi id sebagai identifier unik) dan *Lithology* (yang diubah menjadi *description* berisi deskripsi batuan yang akan diringkas).

Data Selection

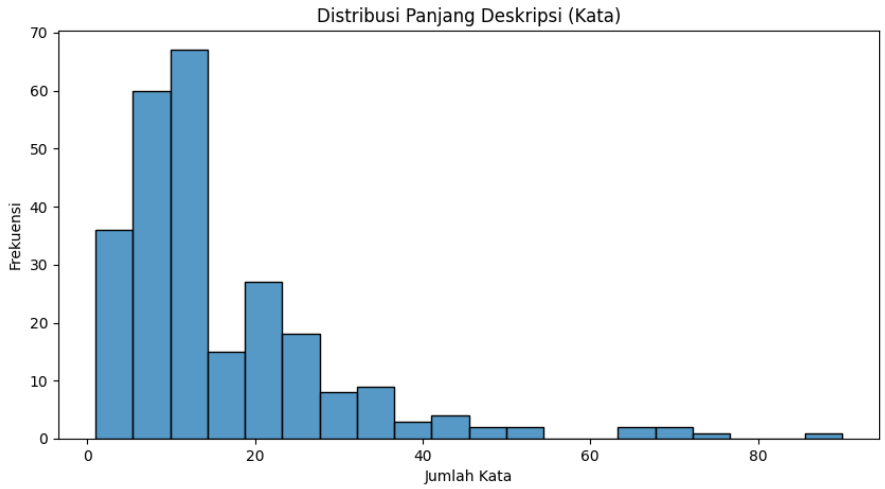
Tahap seleksi data dilakukan untuk memastikan hanya atribut yang relevan dengan tujuan penelitian yang diproses lebih lanjut. Dari 14 atribut yang tersedia, dilakukan penyaringan sehingga hanya dua atribut inti yang dipertahankan:

1. *Station*: Berisi kode identifikasi unik untuk setiap sampel batuan. Atribut ini diubah namanya menjadi id.
2. *Lithology*: Berisi deskripsi tekstual lengkap mengenai karakteristik batuan. Atribut ini diubah namanya menjadi *description* dan merupakan fokus utama dari proses summarisasi.
   Pemilihan kedua atribut ini dilakukan karena secara langsung mendukung tujuan penelitian, yaitu meringkas teks deskripsi batuan (*description*). Data hasil seleksi ini kemudian disimpan dalam format CSV untuk konsistensi dan kemudahan pemrosesan[1], [18].

Analisis Dataset

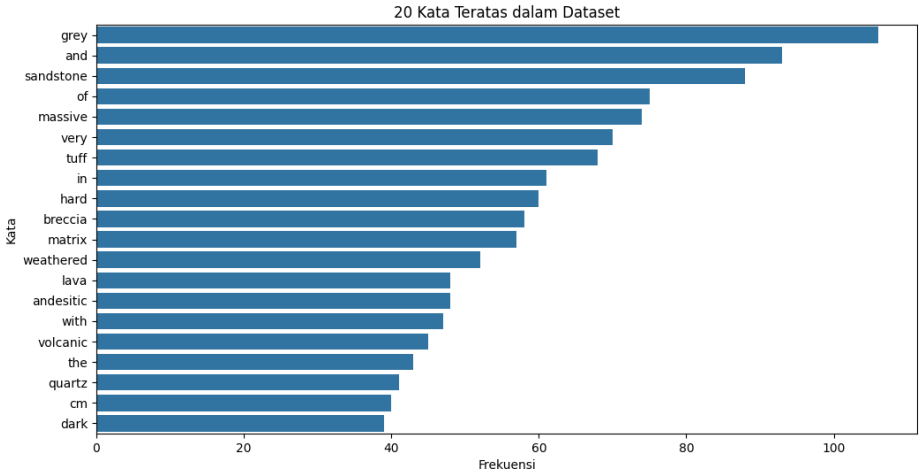
Sebelum pemrosesan lebih lanjut, dilakukan analisis eksploratif pada *Dataset* untuk memahami karakteristik dan kualitasnya [19]. Analisis yang dilakukan meliputi:

1. Ukuran *Dataset*: Memeriksa jumlah baris dan kolom. *Dataset* awal terdiri dari 267 baris.
2. Nilai Hilang dan Duplikat: Mengidentifikasi dan menghitung jumlah nilai null (kosong) dan baris data yang terduplikasi pada kolom *description*. Ditemukan 10 nilai null dan 18 duplikat yang kemudian ditangani pada tahap *Preprocessing*.



Gambar 2. Distribusi Panjang Kata

3. Analisis Panjang Teks: Visualisasi dari gambar 2 mengenai panjang, minimal dan maksimal panjang deskripsi, pada gambar menunjukan *Dataset* memiliki panjang kata mulai dari 1 hingga 90 dengan rata rata di 16 kata per deskripsi.



Gambar 3. 20 Kata Terbanyak Dalam *Dataset*

4. Analisis Frekuensi Kata: Membuat visualisasi (*word cloud*, bar plot) dari kata-kata yang paling sering muncul sebelum *Preprocessing*. Analisis ini mengungkap adanya *stopwords* (*e.g., "the", "of"*) dan simbol yang dominan, yang mengonfirmasi kebutuhan untuk tahap *Preprocessing* [20], [31].

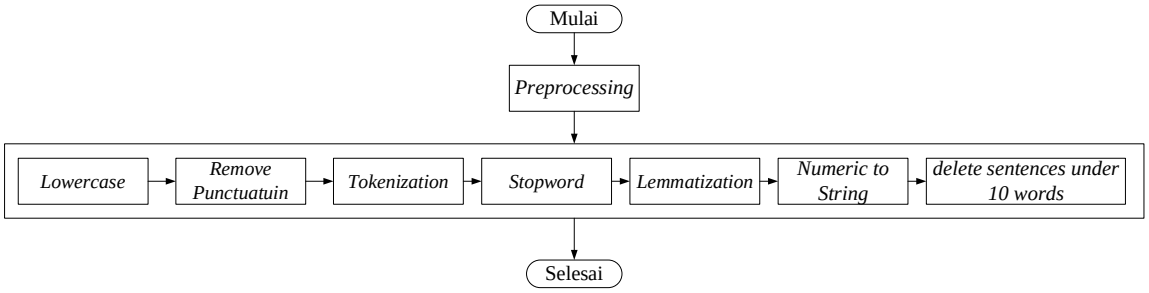
Splitting data

Dataset yang telah melalui seleksi dan analisis kemudian dibagi menjadi dua *Dataset* terpisah untuk menjamin validasi model, *Dataset* akan dibagi menjadi 70:30, 70 untuk data train dan 30 data test, berikut adalah penjelasannya:

1. Data Latih (*Training Set*): Merupakan 70% dari total data yang digunakan untuk melatih model Word2Vec dan melakukan *fine-tuning* pada model BERT, BART, dan T5.
2. Data Uji (*Testing Set*): Merupakan 30% dari total data yang dikhususkan untuk evaluasi akhir performa model. Data ini tidak disertakan dalam proses pelatihan sama sekali dan berfungsi untuk pengujian model dalam bentuk web.

Pembagian 70:30 dipilih sebagai kompromi optimal mengingat ukuran *Dataset* yang tidak terlalu besar, sehingga tetap menjumlah data latih yang cukup untuk model yang kompleks sekaligus mempertahankan data uji yang memadai untuk evaluasi. Pembagian dilakukan secara acak (*random sampling*) dengan menggunakan fungsi *train_test_split* dari *library Scikit-learn* untuk memastikan distribusi yang representatif [6].

Preprocessing



Gambar 1. Alur *Preprocessing*

Tahap *Preprocessing* sangat krusial untuk memastikan kualitas data sebelum pemodelan [19], [20], [28], [32]. Tahapan yang dilakukan adalah:

Cleaning: Menghapus baris data dengan nilai null dan duplikat.

1. *Case Folding*: Mengubah semua karakter menjadi huruf kecil (*lowercase*).
2. *Punctuation Removal*: Menghapus tanda baca seperti simbol, angka dan sebagainnya, kecuali titik (.) yang diperlukan untuk pembatas antar kalimat.
3. *Tokenization*: Memecah teks menjadi unit-unit kata [30]. Tujuannya untuk menyiapkan inputan Word2Vec yang menerima inputan dalam bentuk token atau daftar kata.

4. *Stopword Removal*: Menghapus kata-kata umum yang tidak informatif (e.g., "*the*", "and"), dengan pengecualian untuk istilah geologi yang krusial seperti "*hard*" atau "*massive*" [31]. *Stopword Removal* dilakukan untuk menghilangkan kata-kata umum yang jika di hilangkan pun maknanya akan tetap sama.
5. *Lemmatization*: Mengubah kata ke bentuk dasarnya (e.g., "*fragments*" -> "*fragment*") menggunakan WordNetLemmatizer dari NLTK. Lemmatization atau lematisasi disini berfungsi untuk membuat kata yang memiliki kata yang sama namun konteksnya berbeda menjadi satu, untuk membuat model mengerti bahwa ini adalah kata yang sama.
6. *Number-to-Text Conversion*: Mengonversi angka dan rentang angka (e.g., "15 cm", "10-20 m") menjadi representasi teksnya (e.g., "*fifteen centimeters*", "*ten to twenty meters*") untuk keseragaman. *Number to text coversion* digunakan karena seringkali ukuran atau rentang jarak di dalam teks deskriptif bebatuan itu penting, seperti ukuran batuan, panjang batuan, suhu batuan dan sebgainnya. Sehingga rentang angka ini penting. Namun terdapat tantangan dimana angka tidak efektif untuk dibaca oleh model sehingga perlu dilakukan konfersi dari angka menjadi teks.
7. *Filtering*: Menghapus deskripsi yang memiliki kurang dari 10 kata setelah *Preprocessing*, karena dianggap tidak cukup informatif untuk diringkas.

Berikut adalah perbandingan teks deskripsi sebelum dan sesudah melalui *preprocessing* :

Tabel 1
Perbandingan Teks Deskripsi Sebelum dan Sesudah *Preprocessing*

Description	***Cleaned_Description***
Intercalation of well bedded chert and silicate. Chert, redish brown, compact, hard, // lamination, bedding thickness 0.2 - 10cm,	*['intercalation', 'well', 'bedded', 'chert', 'silicate', '.', 'chert', 'redish', 'brown', 'compact', 'hard', 'lamination', 'bedding', 'thickness', 'zero', 'point', 'two', 'centimeter', 'to', 'ten', 'centimeter']*

Transformation

Teks yang telah dibersihkan kemudian ditransformasikan menjadi representasi numerik melalui dua tahap utama:

1. Word2Vec : Model Word2Vec dengan arsitektur *Skip-gram* dilatih pada korpus teks geologi ini [11], [21]. Setiap kata direpresentasikan sebagai vektor 100-dimensi. Vektor representasi sebuah kalimat dihitung dengan mengambil rata-rata vektor semua kata dalam kalimat tersebut [22].

```
Contoh Vektor Word2Vec untuk 5 kata geologi pertama:
sandstone: [-0.05640504  0.11979581  0.0073041   0.0014775   0.03288949]... (dimensi: 100)
breccia: [-0.05425001  0.09861601  0.005238    0.00186806  0.02465663]... (dimensi: 100)
matrix: [-0.0570403   0.10969944  0.00499489 -0.00013655  0.01678886]... (dimensi: 100)
tuff: [-0.04602876  0.075797    0.00309414  0.0118103   0.01538033]... (dimensi: 100)
grain: [-0.03841173  0.10649772  0.01464454  0.00866838  0.02195966]... (dimensi: 100)
```

Gambar 4. Hasil Vektorisasi Word2Vec

2. SciBERT: Model SciBERT (*pre-trained*) digunakan untuk menghasilkan *embedding* kontekstual tingkat kalimat [24]. Setiap kalimat diproses oleh SciBERT untuk menghasilkan sebuah vektor densitas 768-dimensi yang merepresentasikan maknanya secara utuh.

Modeling

Tiga pendekatan pemodelan dibandingkan dalam penelitian ini:

1. BERT-TextRank (*Extractive*): Vektor gabungan (Word2Vec + SciBERT) dimanfaatkan untuk menghitung cosine similarity antar kalimat. Similaritas ini menjadi bobot tepi pada graf dalam algoritma TextRank. Kalimat dengan skor PageRank tertinggi kemudian diekstrak untuk membentuk ringkasan [12]. Vektor Word2Vec (100-dimensi) diproyeksikan ke ruang 768-dimensi menggunakan sebuah matriks proyeksi. Hasil proyeksi ini kemudian digabungkan (concatenated) dengan vektor SciBERT dari kalimat yang sama, menghasilkan sebuah vektor gabungan yang kaya akan informasi semantik dan kontekstual [12], [14].

2. T5 (*Abstractive*): Model T5 menerima teks masukan dengan prefiks "*summarize*: ". Model kemudian secara langsung menghasilkan rangkaian kata baru yang merupakan ringkasan abstraktif [24].
3. BART (*Abstractive*): Mirip dengan T5, model BART menerima teks deskripsi lengkap dan menghasilkan ringkasan abstraktif melalui proses *sequence-to-sequence* [13].

Evaluation

Kinerja ketiga model dievaluasi pada data *testing* yang belum pernah dilihat model. Metrik evaluasi yang digunakan adalah:

1. ROUGE (ROUGE-1, ROUGE-2, ROUGE-L): Mengukur tumpang tindih n-gram antara ringkasan yang dihasilkan dan teks sumber sebagai referensi [23].
2. BLEU: Mengukur presisi n-gram, umum digunakan untuk evaluasi terjemahan dan generasi teks [24].
3. Cosine Similarity: Mengukur kemiripan semantik dengan membandingkan vektor *embedding* SciBERT dari teks sumber dan teks ringkasan. Metrik ini penting untuk menilai pemertahanan makna [23].
4. Selain evaluasi kuantitatif, dilakukan juga analisis kualitatif dengan mengamati contoh hasil ringkasan untuk menilai koherensi dan retensi istilah teknis [25], [26].

Deployment

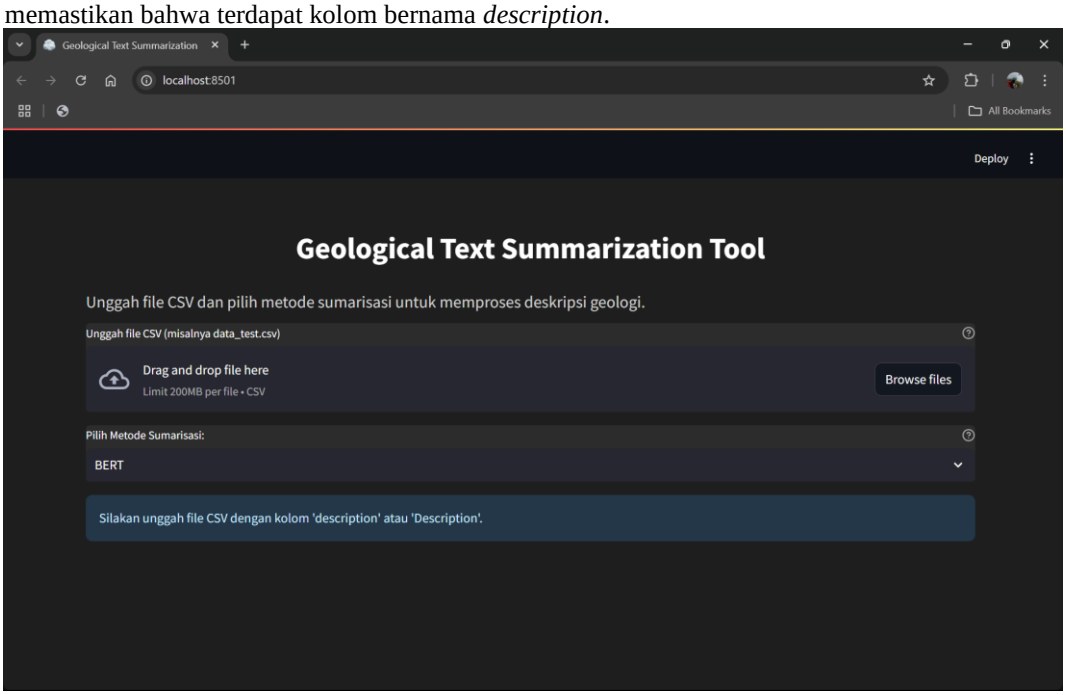
Sebagai bentuk implementasi dari model yang telah dihasilkan, sebuah aplikasi *web* dikembangkan untuk memungkinkan geolog memanfaatkan model summarisasi ini secara praktis [27]. Aplikasi ini dibangun menggunakan *framework* Streamlit yang memungkinkan pembuatan antarmuka *web* yang interaktif dengan menggunakan Python [17], [18].

Arsitektur aplikasi terdiri dari beberapa modul inti:

1. Modul *Preprocessing* (Preprocessing.py): Bertugas menangani pembersihan dan normalisasi teks input yang diunggah oleh pengguna, dengan menerapkan seluruh tahapan *Preprocessing* yang telah dijelaskan sebelumnya [19], [32].
2. Modul Pemodelan (function.py): Berisi implementasi ketiga model summarisasi (BERT-TextRank, T5, BART) serta fungsi untuk menghitung metrik evaluasi.
3. Modul Antarmuka (app.py): Sebagai *front-end* yang mengelola alur kerja aplikasi, menerima input dari pengguna, dan menampilkan hasil [17].

Alur penggunaan aplikasi oleh seorang geolog adalah sebagai berikut:

1. Input: Pengguna (geolog) mengunggah sebuah csv berisikan *Dataset* teks deskripsi geologi. Dan memastikan bahwa terdapat kolom bernama *description*.



Gambar 5. Tampilan utama streamlit.

2. Pemrosesan: Aplikasi secara otomatis menjalankan proses *Preprocessing* pada data yang diunggah.
3. Pemilihan Model: Pengguna dapat memilih model summarisasi yang diinginkan (BERT, T5, atau BART) melalui sebuah menu.

4. Generasi Ringkasan: Setelah pengguna menekan tombol proses, aplikasi akan menjalankan model terpilih untuk menghasilkan ringkasan dari setiap deskripsi batuan.
5. Visualisasi dan Evaluasi: Aplikasi menampilkan hasil ringkasan berdampingan dengan teks asli. Selain itu, aplikasi juga menampilkan visualisasi statistik, seperti grafik batang yang membandingkan panjang teks asli dengan teks ringkasan, serta daftar kata kunci dan bigram yang paling sering muncul dalam ringkasan. Nilai rata-rata metrik evaluasi (ROUGE, BLEU, Cosine Similarity) untuk seluruh *Dataset* juga ditampilkan untuk memberikan gambaran kualitas ringkasan secara kuantitatif [25].
6. *Output*: Pengguna dapat mengunduh hasil ringkasan dalam format CSV untuk keperluan dokumentasi atau analisis lebih lanjut [1].

Antarmuka aplikasi dirancang sederhana dan intuitif untuk memastikan kemudahan penggunaan oleh geolog yang mungkin tidak memiliki latar belakang komputasi yang mendalam. *Deployment* sistem ini berhasil menunjukkan kelayakan integrasi model *machine learning* ke dalam sebuah *workflow* praktis. Purwarupa ini berpotensi untuk dikembangkan lebih lanjut menjadi sebuah modul dalam sistem manajemen database geologi yang lebih besar, dimana ringkasan otomatis dapat membantu dalam pembuatan katalog, pencarian sampel, dan pelaporan yang efisien [4], [5].

IV. HASIL DAN PEMBAHASAN

Hasil

Hasil Sumarisasi:

	Original_Description	Final_Summary
0	Volcanic breccia, massive, high weathered, dark grey, fragments andesite diorite. Fra	volcanic breccia massive high weathered dark grey fragment andesite
2	Phyllite, brecciated (fault breccia), fragment and matrix consist of phyllite. Fault plan	phyllite brecciated fault breccia fragment matrix consist phyllite
3	Breccia, angular, clast supported, febbly, very hard, andesitic fragment. Matrix : very	breccia angular clast supported febbly hard andesitic fragment .
4	Brecciated clay. Components: conglomerats (Quartz, cherts,metamorphic rocks), ma	brecciated clay . component conglomerats quartz chertsmetamorphic rock matrix
7	Andesitic lava, crystalline, grey dark grey, porphyritic coarse. Boulder.	andesitic lava crystalline grey dark grey porphyritic coarse
8	Sandy tuff, medium grain, well bedding, fresh, intercalation of tuffaceous claystone, f	sandy tuff medium grain well bedding fresh intercalation tuffaceous claystone
10	Polymic breccias, sanstone, volcanic rocks, etc; pebbly - boulder, poor bedding, clast	polymic breccia sanstone volcanic rock etc pebbly boulder poor bedding
11	Pumice breccia, thick bedding with polimyc breccia with basaltic andesitic and pumi	pumice breccia thick bedding polimyc breccia basaltic andesitic pumice
12	Pyroclastic deposits, bread crust bomb texture, black, gravelly-boulder; intecallation	pyroclastic deposit bread crust bomb texture black gravellyboulder intecallation peb
18	Andesitic lava, porphyritic medium - coarse texture, grey, crystalline, quartz, amphyb	andesitic lava porphyritic medium coarse texture grey crystalline quartz

Gambar 6. Hasil Sumarisasi Streamlit

Gambar 4.53 menunjukan perbandingan deskripsi sebelum dan sesudah di sumarisasi, dapat dilihat pada kolom *Final_Summary* sudah melakukan tahap *preprocessing* seperti *lowercase*, *Remove Punctuation*, *Remove Stopword* dan sebagainya. Dapat dilihat setiap huruf kapital yang berada di deskripsi original sudah melalui tahapan *lowercase*, selanjutnya simbol-simbol yang semula ada di *original_description* seperti koma, dalam kurung, tutup kurung sudah di hilangkan. Selanjutnya untuk kalimat yang mengandung kata *stopword* juga sudah di hilangkan, dapat dilihat pada urutan ke 6 atau dengan ide 8 dapat terdapat kalimat *itercalation of tuffaceous* setelah di lakukan sumarisasi kata "*of"* sudah dihilangkan menjadi *intercalation tuffaceous*.

Tabel 2
Hasil Rata-Rata Matrix Evaluasi BERT

Rata Rata *Matrix* Evaluasi	
ROUGE-1	54,8%
ROUGE-2	44%
ROUGE-L	54,7%
BLEU	1,4%
Cosine Similarity	81,6%

Model BERT dengan kombinasi *embedding* SciBERT dan Word2Vec , menunjukkan kinerja yang lebih rendah dibandingkan T5 dan BART, dengan ROUGE-1 (54,8%) dan ROUGE-L (54,7%) yang moderat. Ini menunjukkan bahwa BERT, sebagai metode ekstraktif, mampu menangkap kata-kata penting tetapi kurang fleksibel dalam memilih frasa yang lebih kompleks. ROUGE-2 (44%) mengindikasikan kemampuan terbatas dalam mempertahankan pasangan kata berurutan, kemungkinan karena BERT hanya memilih kalimat utuh

tanpa parafrase. Skor BLEU yang sangat rendah (1,4%) mencerminkan sifat ekstraktif yang tidak menghasilkan teks baru, sehingga tumpang tindih n-gram minimal. Cosine Similarity (81,6%)

Tabel 3
Hasil Rata-Rata Matrix Evaluasi BART

Rata Rata Matrix Evaluasi	
ROUGE-1	70,7%
ROUGE-2	58,3%
ROUGE-L	70,7%
BLEU	4,4%
Cosine Similarity	84,8%

Model BART, yang juga berbasis *Transformer* untuk sumarisasi abstraktif, menunjukkan kinerja terbaik di antara ketiga metode, dengan ROUGE-1 dan ROUGE-L sama-sama mencapai 70,7%, menandakan kemampuan unggul dalam menangkap kata kunci dan struktur informasi teks asli. ROUGE-2 (58,3%) lebih tinggi dibandingkan T5, menunjukkan bahwa BART lebih efektif dalam mempertahankan frasa geologi seperti "*tuffaceous sandstone*" atau "*igneous rock*". Skor BLEU (4,4%) sedikit lebih tinggi dari T5, mencerminkan kefluenan yang lebih baik meskipun tetap rendah karena sifat abstraktif. Cosine Similarity (84,8%) adalah yang tertinggi, menunjukkan bahwa ringkasan BART sangat mirip secara semantik dengan teks asli, menjadikannya pilihan ideal untuk sumarisasi teks geologi yang memerlukan keseimbangan antara cakupan informasi dan kefluenan

Tabel 4
Hasil Rata-Rata Matrix Evalasi T5

Rata Rata Matrix Evaluasi	
ROUGE-1	67,9%
ROUGE-2	55,3%
ROUGE-L	67,5%
BLEU	4,1%
Cosine Similarity	83,6%

Model T5, yang merupakan model berbasis *Transformer* untuk sumarisasi abstraktif, menunjukkan kinerja yang baik dengan ROUGE-1 (679%) dan ROUGE-L (67,5%), mengindikasikan bahwa ringkasan T5 mampu menangkap banyak kata kunci geologi (misalnya, "*sandstone*", "*breccia*") dan mempertahankan struktur informasi teks asli. ROUGE-2 (55,3%) menunjukkan bahwa T5 cukup efektif dalam menangkap frasa berurutan, seperti "*igneous rock*", meskipun tidak sekuat dalam koherensi frasa dibandingkan model lain. Skor BLEU yang rendah (4,1%) mencerminkan sifat abstraktif T5, yang menghasilkan parafrase sehingga mengurangi tumpang tindih n-gram langsung. Cosine Similarity (83,6%) menunjukkan kemiripan semantik yang tinggi, menandakan bahwa ringkasan T5 secara semantik dekat dengan teks asli, cocok untuk domain geologi yang membutuhkan fleksibilitas dalam penyusunan ulang informasi.

Kinerja ketiga model dievaluasi secara kuantitatif menggunakan *Dataset testing*. Hasil evaluasi yang mencakup metrik ROUGE, BLEU, dan Cosine Similarity disajikan dalam bentuk persentase pada Tabel 4.

Tabel 5
Perbandingan Hasil Rata-Rata Matrix Evaluasi

Rata-Rata Matrix Evaluasi			
Model	T5	BERT	BART
ROUGE-1	70,7%	65,5%	70,7%
ROUGE-2	58,6%	53,5%	58,3%
ROUGE-L	70,4%	65,4%	70,6%
BLEU	6%	3,6%	5,5%
Cosine Similarity	84,1%	83,7%	84,1%

Berdasarkan Tabel 4, dapat disimpulkan bahwa model BART menunjukkan performa terbaik secara keseluruhan. Model ini mencapai skor tertinggi untuk metrik ROUGE-1 (70.7%) dan ROUGE-L (70.7%), yang mengindikasikan kemampuannya yang unggul dalam mempertahankan kata-kata kunci dan urutan logika dari teks sumber. Skor Cosine Similarity yang sangat tinggi (84.1%) membuktikan bahwa ringkasan yang dihasilkan tidak hanya mengandung kata yang sama, tetapi juga memiliki kemiripan makna semantik yang sangat kuat dengan deskripsi asli. Hal ini merupakan indikator kualitas yang paling krusial untuk menjamin ringkasan tetap akurat secara ilmiah.

Model T5 menunjukkan performa yang sangat kompetitif dan bahkan unggul pada metrik ROUGE-2 (58.6%), yang menunjukkan kemampuannya yang hebat dalam menangkap pasangan kata (*bigrams*) yang penting. Sementara itu, pendekatan ekstraktif BERT-TextRank konsisten menunjukkan performa yang lebih rendah *across all metrics*. Hal ini mengonfirmasi bahwa untuk tugas summarisasi teks geologi, pendekatan abstraktif secara signifikan lebih efektif daripada sekadar mengekstrak kalimat secara langsung.

Pembahasan

Tingginya skor Cosine Similarity yang dicapai oleh semua model (>83%) merupakan indikator yang sangat positif. Hal ini menunjukkan bahwa baik model abstraktif (BART, T5) maupun ekstraktif (BERT-TextRank) mampu memahami makna fundamental dari deskripsi geologi. Namun, keunggulan BART pada metrik ROUGE mengonfirmasi bahwa model ini tidak hanya paham, tetapi juga mampu mengekspresikan pemahaman tersebut kembali dalam bentuk teks yang paling ringkas dan informatif

Skor BLEU yang rendah pada semua model adalah hal yang telah terantisipasi. Metrik BLEU mengukur kesesuaian literal (kata-per-kata), sedangkan summarisasi abstraktif yang baik justru menghindari penyalinan literal dan lebih mengutamakan parafrase. Oleh karena itu, metrik ini kurang relevan untuk mengukur kualitas summarisasi abstraktif dan hasil yang rendah bukanlah indikator kegagalan.

Keberhasilan model ini didukung oleh pipeline *Preprocessing* yang robust, khususnya dalam penanganan istilah teknis dan angka. Konversi "15 cm" menjadi "*fifteen centimeters*" memastikan konsistensi data yang pada akhirnya membantu model dalam proses pembelajaran dan generasi teks.

V. KESIMPULAN DAN SARAN

Kesimpulan

Berdasarkan seluruh tahapan penelitian yang telah dilakukan, dapat disimpulkan bahwa:

1. Model BART merupakan model terbaik untuk tugas summarisasi teks deskriptif batuan geologi. Model ini berhasil menghasilkan ringkasan dengan kualitas tertinggi, yang ditunjukkan oleh skor ROUGE-1 70.8%, ROUGE-L 70.7%, dan Cosine Similarity 84.1%. Keunggulan ini dikarenakan kemampuannya dalam *Abstractive summarization* yang menghasilkan ringkasan yang padat, koheren, dan kaya akan istilah teknis yang akurat.
2. Pendekatan abstraktif (BART, T5) secara signifikan lebih unggul dibandingkan pendekatan ekstraktif (BERT-TextRank) untuk tugas ini. Kemampuan model abstraktif untuk memparafrase dan menghasilkan kata-kata baru terbukti lebih efektif dalam menciptakan ringkasan yang informatif dan alami bagi geolog.
3. Pipeline *Preprocessing* yang komprehensif—yang mencakup pembersihan data, preservasi titik, lematisasi, dan konversi angka-ke-teks—sangat krusial dalam mempersiapkan data teks teknis geologi untuk pemodelan yang optimal.
4. Purwarupa aplikasi *web* yang dikembangkan berhasil mendemonstrasikan kelayakan integrasi model *machine learning* ke dalam sebuah alat bantu yang dapat digunakan oleh geolog secara langsung untuk mempercepat proses analisis dan dokumentasi data batuan.

5. Dengan demikian, penelitian ini telah berhasil mencapai tujuannya dalam mengembangkan model summarisasi otomatis yang efektif untuk domain geologi, yang mana dapat memberikan nilai praktis yang tinggi bagi para praktisi.

Saran

Untuk pengembangan penelitian selanjutnya, beberapa saran dapat dipertimbangkan:

1. Ekspansi dan Pengayaan Data: Penelitian lebih lanjut dapat dilakukan dengan menambah jumlah dan variasi data latih, mencakup lebih banyak jenis batuan dan variasi deskripsi dari sumber yang lebih beragam, untuk meningkatkan kemampuan generalisasi model.
2. Eksplorasi Model dan Teknik Lain: Perlu dilakukan eksperimen dengan arsitektur *Transformer* lainnya yang lebih mutakhir (seperti PEGASUS yang khusus dirancang untuk summarisasi) serta teknik *fine-tuning* yang lebih mendalam pada model SciBERT untuk memaksimalkan pemahaman konteks ilmiah.
3. Pengembangan Kamus Domain-Spesifik: Pembuatan dan integrasi kamus istilah geologi yang lebih lengkap dan komprehensif dapat meningkatkan akurasi *Preprocessing* dan kualitas ringkasan dengan menjaga konsistensi terminologi.
4. Evaluasi Kualitatif oleh Ahli (*Human Evaluation*): Saran yang paling krusial adalah melengkapi evaluasi kuantitatif dengan evaluasi kualitatif oleh ahli geologi. Sebuah studi yang melibatkan para geolog untuk menilai relevansi, akurasi, dan kegunaan ringkasan dari sudut pandang mereka akan memberikan validasi yang jauh lebih kuat dan *meaningful* terhadap efektivitas model dalam mendukung pekerjaan mereka.
5. Optimasi *Deployment*: Purwarupa aplikasi dapat dikembangkan lebih lanjut untuk diintegrasikan ke dalam sistem manajemen database geologi yang sudah ada, menambahkan fitur seperti penyimpanan history, kolaborasi, dan kemampuan pencarian yang lebih canggih berdasarkan ringkasan yang dihasilkan.

DAFTAR PUSTAKA

[1] R. Rosaly, A. Prasetyo, *and* M. Kom, "Pengertian Flowchart Beserta Fungsi dan Simbol-simbol Flowchart yang Paling Umum Digunakan," 2019.

[2] S. Li, J. Chen, *and* C. Liu, "Overview on *the* Development *of* Intelligent Methods for Mineral Resource Prediction under *the* Background *of* Geological *Big data*," May 01, 2022, *MDPI*. doi: 10.3390/min12050616.

[3] A. Nursikuwagus, R. Munir, *and* M. L. Khodra, "Hybrid *of Deep learning and Word embedding* in Generating Captions: Image-Captioning Solution for Geological *Rock* Images," *J Imaging*, vol. 8, no. 11, Nov. 2022, doi: 10.3390/jimaging8110294.

[4] C. J. M. Lawley, M. G. Gadd, M. Parsa, G. W. Lederer, G. E. Graham, *and* A. Ford, "Applications *of Natural Language Processing* to Geoscience *Text* Data *and* Prospectivity Modeling," *Natural Resources Research*, vol. 32, no. 4, pp. 1503–1527, Aug. 2023, doi: 10.1007/s11053-023-10216-1.

[5] S. Peyghambari *and* Y. Zhang, "Hyperspectral *remote sensing* in lithological mapping, mineral exploration, *and* environmental geology: an updated review," *J Appl Remote Sens*, vol. 15, no. 03, Jul. 2021, doi: 10.1117/1.jrs.15.031501.

[6] B. Mahesh, "*Machine learning* Algorithms - A Review," *International Journal of Science and Research (IJSR)*, vol. 9, no. 1, pp. 381–386, Jan. 2020, doi: 10.21275/art20203995.

[7] V. Kieuvongngam, B. Tan, *and* Y. Niu, "*Automatic Text Summarization of* COVID-19 Medical Research Articles using BERT *and* GPT-2," Jun. 2020, [Online]. Available: http://arxiv.org/abs/2006.01997

[8] A. Sarker, Y. C. Yang, M. A. Al-Garadi, *and* A. Abbas, "A Light-Weight *Text Summarization* System for Fast Access to Medical Evidence," *Front Digit Health*, vol. 2, Dec. 2020, doi: 10.3389/fdgth.2020.585559.

[9] H. Ahonen, O. Heinonen, M. Klemettinen, *and* A. I. Verkamo, "Applying *Data mining* Techniques in *Text* Analysis," 1997.

[10] A.-H. Tan, "*Text* Mining: *The* state *of the* art *and the* challenges," 2000. [Online]. Available: https://www.researchgate.net/publication/2471634

[11] H. D. Abubakar *and* M. Umar, "Sentiment Classification: Review *of Text* Vectorization Methods: Bag *of Word*s, Tf-Idf, Word2Vec *and* Doc2vec," *SLU Journal of Science and Technology*, vol. 4, no. 1 & 2, pp. 27–33, Aug. 2022, doi: 10.56471/slujst.v4i.266.

[12] E. Yulianti, N. Pangestu, *and* M. A. Jiwanggi, "Enhanced TextRank using weighted *word embedding* for *text summarization*," *International Journal of Electrical and Computer Engineering*, vol. 13, no. 5, pp. 5472–5482, Oct. 2023, doi: 10.11591/ijece.v13i5.pp5472-5482.

[13] M. La Quatra *and* L. Cagliero, "BART-IT: An Efficient *Sequence-to-sequence* Model for Italian *Text Summarization*," *Future Internet*, vol. 15, no. 1, Jan. 2023, doi: 10.3390/fi15010015.

[14] Z. Li, M. Xu, X. Yang, *and* Y. Han, "Multi-Label Fundus Image Classification Using Attention Mechanisms *and* Feature Fusion," *Micromachines (Basel)*, vol. 13, no. 6, Jun. 2022, doi: 10.3390/mi13060947.

[15] J. Foster *and* J. Wagner, "Naive Bayes versus BERT: Jupyter notebook assignments for an introductory NLP course," 2021. [Online]. Available: https://colab.research.google.com

[16] M. Han, Y. Wang, Z. Li, L. Yao, X. Chang, *and* Y. Qiao, "HTML: Hybrid Temporal-scale Multimodal Learning *Framework* for Referring Video Object Segmentation," 2023. [Online]. Available: https://mingfei.info/HTML/

[17] A. A. Saputra *et al.*, "PELATIHAN DAN PEMBUATAN WEBSITE MENGGUNAKAN HTML DAN CSS," *Beujroh : Jurnal Pemberdayaan dan Pengabdian pada Masyarakat*, vol. 1, no. 1, pp. 119–125, Dec. 2023, doi: 10.61579/beujroh.v1i1.41.

[18] C. S. Li, S. A. Mostafa, F. S. Komputer, *and* T. Maklumat, "Design *and* Development *of* SDR System using PHP *and* HTML," *Applied Information Technology And Computer Science*, vol. 4, no. 1, pp. 997–1011, 2023, doi: 10.30880/aitcs.2023.04.01.057.

[19] M. Kashif, M. Ibrahim, M. Iqbal, *and* U. Abiha, "Data *Preprocessing* Platform for Machine Learning," 2023.

[20] A. Tabassum *and* R. R. Patil, "A Survey on *Text* Pre-Processing & Feature Extraction Techniques in *Natural Language Processing*," *International Research Journal of Engineering and Technology*, 2020, [Online]. Available: www.irjet.net

[21] H. D. Abubakar *and* M. Umar, "Sentiment Classification: Review *of Text* Vectorization Methods: Bag *of Word*s, Tf-Idf, Word2Vec *and* Doc2vec," *SLU Journal of Science and Technology*, vol. 4, no. 1 & 2, pp. 27–33, Aug. 2022, doi: 10.56471/slujst.v4i.266.

[22] I. Budiman, M. Faisal, *and* D. Nugrahadi, "Studi Ekstraksi Fitur Berbasis Vektor Word2Vec pada Pembentukan Fitur Berdimensi Rendah," 2020.

[23] S. Xu, X. Zhang, Y. Wu, *and* F. Wei, "Sequence Level Contrastive Learning for *Text Summarization*," 2022. [Online]. Available: www.aaai.org

[24] H. Zhang, J. Xu, *and* J. Wang, "Pretraining-Based Natural Language Generation for *Text Summarization*," Feb. 2019, [Online]. Available: http://arxiv.org/abs/1902.09243

[25] A. R. Fabbri *et al.*, "SummEval: Re-evaluating *Summarization* Evaluation," 2021, doi: 10.1162/tacl.

[26] N. Wu, M. Gong, L. Shou, S. Liang, *and* D. Jiang, "Large Language Models are Diverse Role-P*layers* for *Summarization* Evaluation," Mar. 2023, [Online]. Available: http://arxiv.org/abs/2303.15078

[27] S. Patil *and* V. Lokesha, "LIVE TWITTER SENTIMENT ANALYSIS USING STREAMLIT *FRAMEWORK* ," 2022. [Online]. Available: https://ssrn.com/abstract=4119949

[28] Z. Qiang, K. Taylor, *and* W. Wang, "How Does A *Text Preprocessing* Pipeline Affect Ontology Syntactic Matching?," Nov. 2024, [Online]. Available: http://arxiv.org/abs/2411.03962

[29] X. Ye, Q. Chen, I. Dillig, *and* G. Durrett, "Benchmarking Multimodal Regex Syn*thes*is with Complex Structures," May 2020, [Online]. Available: http://arxiv.org/abs/2005.00663

[30] C. W. Schmidt *et al.*, “Tokenization Is More Than Compression,” Feb. 2024, [Online]. Available: http://arxiv.org/abs/2402.18376

[31] F. Alshanik, A. Apon, A. Herzog, I. Safro, *and* J. Sybrandt, “Accelerating *Text* Mining Using Domain-Specific Stop *Word* Lists,” Nov. 2020, [Online]. Available: http://arxiv.org/abs/2012.02294

[32] A. Petukhova *and* N. Fachada, “*Text*CL: A Python package for NLP *Preprocessing* tasks,” *SoftwareX*, vol. 19, Jul. 2022, doi: 10.1016/j.s*oft*x.2022.101122.

[33] M. Chiny, M. Chihab, A. A. Lahcen, O. Bencharef, *and* Y. Chihab, “Effect *of word embedding* vector dimensionality on sentiment analysis through short *and* long *text*s,” *IAES International Journal of Artificial Intelligence*, vol. 12, no. 2, pp. 823–830, Jun. 2023, doi: 10.11591/ijai.v12.i2.pp823-830.